Python Insights - Analisando Dados com Python

Case - Cancelamento de Clientes

Você foi contratado por uma empresa com mais de 800 mil clientes para um projeto de Dados. Recentemente a empresa percebeu que da sua base total de clientes, a maioria são clientes inativos, ou seja, que já cancelaram o serviço.

Precisando melhorar seus resultados ela quer conseguir entender os principais motivos desses cancelamentos e quais as ações mais eficientes para reduzir esse número.

Base de dados e arquivos: https://drive.google.com/drive/folders/1uDesZePdkhiraJmiyeZ-w5tfc8XsNYFZ?usp=drive_link

```
# Passo a passo:
# Passo 1: Importar base de dados
import pandas as pd
table = pd.read_csv('cancelamentos.csv')
# Remove a coluna CustomerID que não vai servir
table = table.drop(columns="CustomerID")
display(table)

# Passo 2: Visualizar base de dados
# !pip install pandas numpy openpyxl nbformat ipykernel plotly
# Passo a passo do projeto
```

	idade	sexo	tempo_como_cliente	frequencia_uso	ligacoes_callcenter	dias_atraso	assinatura	dura
0	30.0	Female	39.0	14.0	5.0	18.0	Standard	
1	65.0	Female	49.0	1.0	10.0	8.0	Basic	
2	55.0	Female	14.0	4.0	6.0	18.0	Basic	
3	58.0	Male	38.0	21.0	7.0	7.0	Standard	
4	23.0	Male	32.0	20.0	5.0	8.0	Basic	
...	...	...	...	...	...	...	...	
881661	42.0	Male	54.0	15.0	1.0	3.0	Premium	
881662	25.0	Female	8.0	13.0	1.0	20.0	Premium	
881663	26.0	Male	35.0	27.0	1.0	5.0	Standard	
881664	28.0	Male	55.0	14.0	2.0	0.0	Standard	
881665	31.0	Male	48.0	20.0	1.0	14.0	Premium	

881666 rows × 11 columns

```
# Passo 3: Corrigir cagadas da base de dados
# Valores vazios na base de dados e formatos corretos na base de dados
# Valores vazios NaN =  Not a Number
table = table.dropna()
display(table.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 881659 entries, 0 to 881665
Data columns (total 11 columns):
 #   Column                  Non-Null Count   Dtype
---  ------                  --------------   -----
 0   idade                   881659 non-null  float64
 1   sexo                    881659 non-null  object
 2   tempo_como_cliente      881659 non-null  float64
 3   frequencia_uso          881659 non-null  float64
 4   ligacoes_callcenter     881659 non-null  float64
 5   dias_atraso             881659 non-null  float64
 6   assinatura              881659 non-null  object
 7   duracao_contrato        881659 non-null  object
 8   total_gasto             881659 non-null  float64
 9   meses_ultima_interacao  881659 non-null  float64
 10  cancelou                881659 non-null  float64
dtypes: float64(8), object(3)
memory usage: 80.7+ MB
None
```

```
# Passo 4: Análise dos cancelamentos
display(table["cancelou"].value_counts())
# Calcula o percentual
display(table["cancelou"].value_counts(normalize=True))
```

```
cancelou
1.0    499993
0.0    381666
Name: count, dtype: int64
cancelou
1.0    0.567105
0.0    0.432895
Name: proportion, dtype: float64
```

```
# Passo 5: Análise da causa dos cancelamentos (como as colunas impactam no cancelamento?)
# Gráficos
# Importar a biblioteca de gráficos
import plotly.express as px
# Criar os gráficos
for column in table.columns:
    graph = px.histogram(table, x=column, color="cancelou")
    # Exibir o gráfico
    graph.show()
```

```
# Clientes do contrato mensal sempre cancelam
    # Solução: Desconto para contratos anuais e trimestrais
# Se co cliente liga mais de 4 vezes, ele vai cancelar
    # Solução: Acionar um alerta para quando o cliente ligar 3 vezes e resolver o problema dele
# Clientes acima de 50 anos cancelam
# Clientes com mais de 20 dias de atraso cancelam
    # Solução: Cobrar o cliente veaco caloteiro quando atingir 10 dias de atraso

# Criar filtros na tabela

# Caso eu não tenha clientes de contrato mensal, como seria?
table = table[table["duracao_contrato"] != "Monthly"]

# Caso eu não tenha clientes com mais de 4 ligações pro call center, como seria?
table = table[table["ligacoes_callcenter"] <=4]

# Caso eu não tenha clientes com mais de 20 dias de atraso, como seria?
table = table[table["dias_atraso"] <=20]
```